Szablon sprawozdania laboratoryjnego

****Przedmiot:**** Uczenie głębokie do rozpoznawania obiektów

****Zajęcia nr / temat:**** 4 / CNN – splotowe sieci dla obrazów

****Autor / grupa:**** Mateusz Pluta / GL5.03

****Data:**** 04.11.2026r.

1. Cel ćwiczenia

Celem ćwiczenia jest zaprojektowanie, zaimplementowanie i przetestowanie prostej sieci splotowej (CNN) oraz porównanie jej wydajności z wielowarstwowym perceptronem (MLP) na kolorowym zbiorze danych CIFAR-10. Badanie ma na celu wykazanie zalet wykorzystania lokalnej struktury obrazu (ekstrakcja cech przestrzennych, współdzielenie wag) w odniesieniu do jakości klasyfikacji, liczby parametrów i kosztu obliczeniowego (czasu uczenia).

2. Metoda i implementacja

- Wykorzystane narzędzia, modele i zbiory danych: PyTorch, torchvision, Matplotlib

- Link do repozytorium/notatnika: https://github.com/mattty1/Uczenie-glebokie-do-rozpoznawania-obiektow.git

- Konfiguracja (architektura, hiperparametry, augmentacje):

Liczba epok: 10

Batch size: 128 trening, 256 test

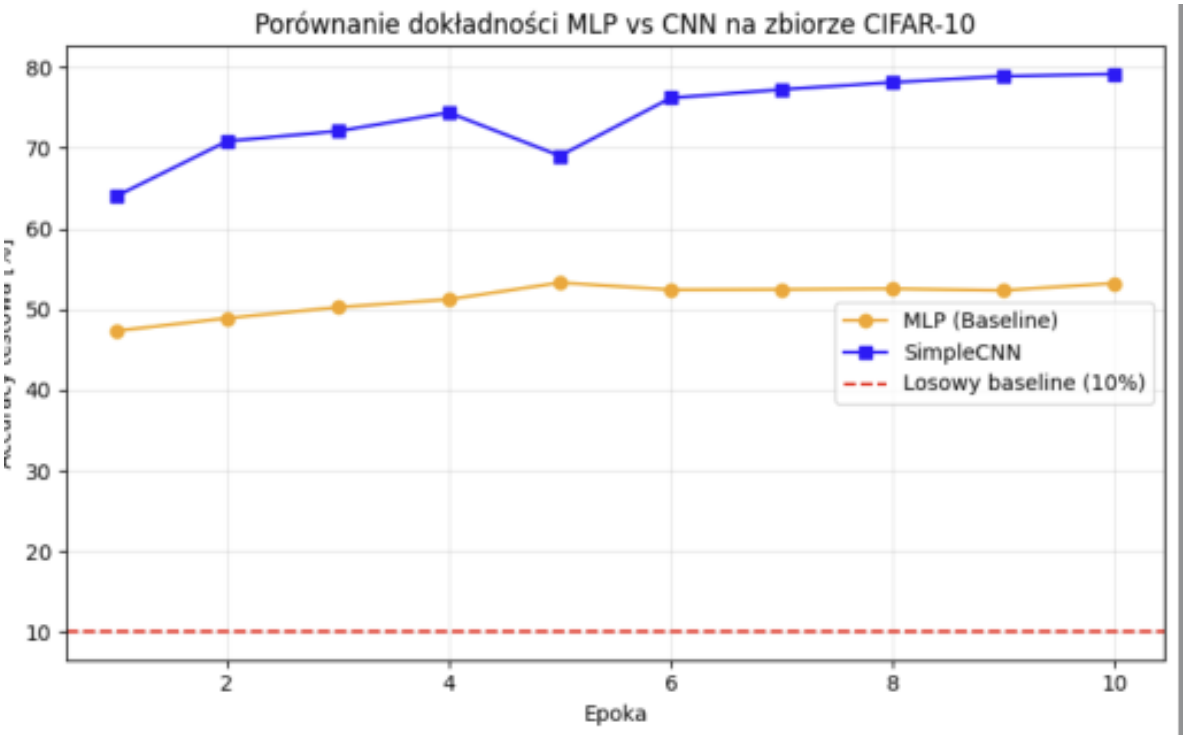
Optymalizator: Adam (lr=0.001)

MLP

SimpleCNN

3. Wyniki

Model	Liczba parametrów	Najlepsza Accuracy Testowa (%)	Czas uczenia (10 epok) [s]
Losowy Baseline	—	10.00%	—
MLP (Baseline)	1 707 274	~53.30%	~130.7 s
SimpleCNN	1 117 354	~79.16%	~143.9 s



4. Analiza i interpretacja

Oba modele znacznie przewyższają losowy baseline (10%). Sieć splotowa uzyskała dokładność testową na poziomie ~79.60%, podczas gdy model MLP osiągnął jedynie ~54.14% (różnica wynosząca ponad 25 punktów procentowych na korzyść CNN).

Sieć CNN posiada znacznie mniej parametrów (ok. 1.11 mln) w porównaniu do sieci MLP (ok. 1.71 mln).wynika to bezpośrednio z dwóch cech sieci splotowych:

- Współdzielenie wag (Weight Sharing): Filtry splotowe (np. 3×3) przesuwają się po całym obrazie, używając tych samych wag dla wszystkich pozycji.
- Lokalność (Local Receptive Fields): Neurony łączą się tylko z lokalnymi sąsiedztwami pikseli, a nie ze wszystkimi wejściami naraz, jak ma to miejsce w warstwie fully-connected MLP.

MLP traktuje obraz jako 1D wektor (3072 wartości), tracąc zależności przestrzenne (pionowe i poziome relacje pikseli). CNN zachowuje układ 2D pikseli oraz 3 kanały koloru, co pozwala na hierarchiczne wyciąganie cech (od prostych krawędzi do złożonych kształtów).

Czas uczenia CNN był nieznacznie wyższy niż MLP (mimo mniejszej liczby parametrów), ze względu na intensywność obliczeniową operacji splotu (Convolution) oraz przetwarzanie przez Batch Normalization.

5. Wnioski

-Wykorzystanie struktury obrazu w architekturze CNN pozwala na osiągnięcie znacznie wyższej jakości klasyfikacji przy wyraźnie mniejszym skomplikowaniu modelu (mniejsza liczba parametrów).

-Spłaszczenie obrazów RGB w modelu MLP prowadzi do utraty informacji przestrzennej i szybkiego przeuczenia na szumie zamiast na cechach strukturalnych.

Kierunki poprawy: Aby dalej poprawiać accuracy CNN na CIFAR-10, można zastosować:

- Augmentację danych (np. RandomHorizontalFlip, RandomCrop),
- Głębszą architekturę (np. dodanie kolejnego bloku splotowego z 128 filtrami),
- Harmonogram zmiany współczynnika uczenia (Learning Rate Scheduler),
- Wykorzystanie uczenia transferowego (Transfer Learning) z sieci ResNet.

Kryteria oceny (rubryka)

| Element | Waga |

|---|---|

| Poprawność implementacji | 40% |

| Wyniki i ich interpretacja | 30% |

| Czytelność kodu (PEP8, komentarze) | 20% |

| Wnioski | 10% |

Próg zaliczenia sprawozdań (O1): 90%. Oddanie: do tygodnia po zajęciach.